

POSTECH



DESAFIO

O Datathon propõe um desafio único no domínio financeiro regulado: projetar uma plataforma de experimentação adaptativa para ofertas, mensagens ou próximos passos em canais digitais. Cada grupo constrói uma solução end-to-end de Machine Learning Engineering e demonstra como ela seria operada com segurança, observabilidade, avaliação e governança.

O objetivo não é reproduzir um sistema bancário real, mas sim mostrar maturidade técnica: formular o problema, construir baselines, versionar dados, servir componentes, avaliar qualidade, monitorar risco, documentar limitações e explicar decisões para públicos técnicos e de negócio, considerando o seguinte caso:

Uma instituição financeira digital precisa decidir, em diferentes canais, qual oferta, mensagem ou próximo passo apresentar para cada cliente elegível. Regras fixas e testes A/B longos desperdiçam tráfego, demoram para reagir a mudanças de contexto e dificultam a personalização responsável. Esse é o ponto central de uma abordagem de multi-armed bandit: identificar comportamentos distintos, equilibrar exploração e exploração e aprender com respostas observadas sem congelar a decisão em regras estáticas. A solução deve incluir um assistente com LLM que resuma experimentos, recupere políticas internas sintéticas e explique decisões.

Referências algorítmicas

Algoritmo	Papel no desafio	Evidência esperada
Thompson Sampling	Exploração bayesiana sob incerteza para modelar conversão, clique ou recompensa esperada por braço.	Priors documentados, comparação com baseline e análise de exploração.
Nilos-UCB	Família UCB para selecionar ações com base em recompensa esperada e incerteza.	Fórmula, implementação ou adaptação justificada, com análise do trade-off entre confiança, exploração e conversão.
Baseline determinístico	Política simples de controle (regra fixa, melhor braço histórico ou segmentação inicial).	Métrica comparativa clara para mostrar ganho ou limitação da política adaptativa.

O grupo pode implementar Thompson Sampling, Nilos-UCB, LinUCB ou outra variação contextual, desde que explique a escolha, mostre como o contexto entra na decisão e documente o tratamento de recompensas atrasadas.

Dados, regras e bases kaggle

Use uma base Kaggle compatível com marketing, ofertas, propensão, campanhas, recomendação ou conversão como referência factual e crie uma camada sintética de experimentação adaptativa sobre ela (impressões, ações, contexto, recompensas, eventos atrasados, documentos de política comercial e suitability para RAG). Não use dados reais de clientes, identificadores, patrimônio, renda, gênero, raça ou regras comerciais privadas. Mantenha decisões sensíveis com humano no loop e documente base legal, finalidade, minimização e retenção.

Base Kaggle	Como usar no desafio
bank-marketing (henriqueyamahata)	Campanhas bancárias, propensão de conversão e decisão de oferta.
bank-marketing-data-set (tunguz)	Variação do problema de marketing bancário para comparação.
bank-term-deposit-subscription (dharmik34)	Assinatura de depósito a prazo como proxy de conversão.
telemarketing-jyb-dataset (aguado)	Campanhas de contato e resposta, útil para comparação de canal ou abordagem.

Outras bases são aceitas se o grupo justificar a aderência e documentar fonte, versão, licença, colunas, target e limitações. Descarte colunas de vazamento temporal (ex.: duration no Bank Marketing) e preserve a referência ao Kaggle. Cada grupo deve entregar, no mínimo, uma camada derivada versionada contendo:

- data/kaggle/README.md (fonte, link, versão, licença);
- data/processed/ (base tratada sem vazamento);

- `data/synthetic_enrichment/` com `offer_catalog`, `offer_events` e `delayed_rewards`;
- `data/golden_set/evaluation_cases.jsonl` com pelo menos 20 casos;
- e `reports/data-generation.md` documentando processo, sementes, hipóteses, limitações e riscos.

Entregáveis obrigatórios

Os entregáveis abaixo são organizados em nove etapas acumulativas (0–8). Cada etapa traz um objetivo, uma lista detalhada de artefatos técnicos exigidos e o critério de evidência de aceite que a banca usa para considerar a etapa cumprida. Uma etapa posterior não compensa uma etapa anterior ausente: um grupo com modelo sofisticado, mas sem dataset rastreável, avaliação reproduzível ou aprovação de ciclo de vida é penalizado na validação técnica. A ausência de um subitem dentro de uma etapa não é compensada pela presença dos demais.

Etapa 0 — Organização do projeto

Objetivo: preparar um repositório público reutilizável por outra pessoa sem contexto oral do grupo.

- URL pública do repositório com nome no padrão *datathon-7mlet-grupo-XX*.
- `README.md` com visão do problema, escopo, escolhas de design, instruções de execução local, mapa de pastas, lista de comandos e limitações.
- `pyproject.toml` declarando dependências, versão de Python, ponto de entrada e ferramentas de desenvolvimento.
- `.env.example` listando variáveis de ambiente necessárias, sem valores reais.
- Licença, `.gitignore` adequado e ausência de segredos, dados sensíveis ou modelos binários grandes versionados.
- Histórico de commits que mostre evolução do trabalho, não apenas um commit final.

Evidência de aceite: uma pessoa externa consegue instalar dependências, entender o fluxo e executar pelo menos um comando de validação sem precisar de explicação oral do grupo.

Etapa 1 — Base Kaggle e EDA

Objetivo: transformar uma base Kaggle compatível em fonte confiável para experimentação.

- data/kaggle/README.md com link, versão, fonte, licença, limitações e instruções de download.
- Dicionário de dados, notebook de EDA e relatório de qualidade.
- Camada de dados em código que carrega a base, registra fonte/versão/licença e gera os datasets derivados documentados.
- Decisão documentada sobre colunas que geram vazamento temporal ou pós-contato, com justificativa de descarte ou tratamento.

Evidência de aceite: a banca consegue rastrear a origem do dataset, entender as variáveis usadas e verificar que não houve vazamento de informação pós-contato no modelo de decisão.

Etapa 2 — Enriquecimento sintético

Objetivo: criar a camada de experimentação adaptativa sobre o dataset escolhido.

- Catálogo sintético de braços/ofertas separado fisicamente da base Kaggle original.
- Eventos de impressão, contexto de decisão e recompensas intermediárias com sementes aleatórias controladas.
- Modelagem de delayed rewards e do horizonte temporal documentada.
- Schema dos arquivos sintéticos e processo de geração descritos no repositório.

Evidência de aceite: os arquivos sintéticos têm schema documentado e explicam como braços, contexto, recompensa e horizonte temporal foram definidos, separados da base Kaggle original.

Etapa 3 — Baseline e estratégia algorítmica

Objetivo: comparar política simples com abordagem multi-armed bandit.

- Pelo menos um baseline determinístico implementado.
- Implementação ou simulação de Thompson Sampling.
- Referência experimental ou justificativa explícita de Nilos-UCB na análise algorítmica.
- Métricas de recompensa, regret, exploração e conversão simulada calculadas e reportadas.
- Tratamento de cold-start e de recompensas atrasadas descrito.

Evidência de aceite: o grupo apresenta comparação quantitativa entre baseline e política adaptativa, com justificativa do algoritmo escolhido e do tratamento de cold-start e delayed rewards.

Etapa 4 — Avaliação offline e golden set

Objetivo: medir qualidade técnica e risco antes de servir a decisão.

- Script ou notebook de avaliação offline reproduzível por linha de comando ou notebook, com métricas justificadas.
- Golden set com no mínimo 20 exemplos versionados em `data/golden_set/evaluation_cases.jsonl` ou formato equivalente.
- Cobertura do golden set sobre casos típicos, casos de borda, segmentos sintéticos elegíveis e cenários adversariais.
- Cada caso traz contexto, ação esperada, recompensa esperada, justificativa e critério explícito de pass/fail.
- Matriz de métricas, análise de sensibilidade e análise de fairness de exposição entre segmentos sintéticos.

Evidência de aceite: as métricas são reproduzíveis, o golden set está versionado e a análise explica limitações, vieses e condições em que a política não deve ser usada.

Etapa 5 — Serviço ou interface demonstrável

Objetivo: expor a decisão de forma controlada e auditável.

- API, CLI, notebook executável ou app demonstrável que recebe um contexto e devolve uma decisão.
- Contrato de entrada e saída documentado, com exemplo de chamada e tratamento de erro.
- Log auditável de decisão com reason codes, braço selecionado e versão da política aplicada.
- Comando único ou script que permita reproduzir o pipeline ponta a ponta em ambiente local.
- Suíte mínima de testes automatizados cobrindo contratos de dados, política e registro de decisão.

Evidência de aceite: a banca consegue executar uma decisão de exemplo, ver o braço selecionado, a justificativa, a versão da política e o registro auditável gerado.

Etapa 6 — Arquitetura-alvo Azure

Objetivo: demonstrar como a solução seria operada em Azure.

- docs/architecture-azure.md com diagrama Mermaid e mapeamento de serviços Azure.
- Plano de deploy e estimativa qualitativa de custo.
- Cobertura das camadas de compute, API, dados, IA/RAG, observabilidade, segurança, identidade e governança.
- Plano de gestão de segredos e credenciais usando Azure Key Vault e Managed Identity.

Evidência de aceite: a arquitetura usa exclusivamente Azure, cobre as camadas acima e justifica trade-offs sem depender de outro provedor de nuvem.

Etapa 7 — Ciclo de vida MLOps

Objetivo: mostrar como novas políticas seriam testadas, aprovadas e promovidas.

- Plano de retreino com critérios de promoção, approval gate, rollback e versionamento de política.
- Monitoramento de drift e de recompensa documentado.
- Rastreo de experimentos em MLflow ou ferramenta equivalente.
- Procedimento de teste, aprovação humana estruturada e promoção de novas políticas para produção controlada.

Evidência de aceite: o grupo demonstra como uma nova hipótese de oferta/canal/mensagem sairia de experimento para produção controlada, com aprovação humana e rollback documentado.

Etapas 8 — Governança, Demo Day e relatórios

Objetivo: fechar a entrega com responsabilidade operacional e narrativa coerente.

- docs/model-card.md com nome do modelo, versão, dados de treino e avaliação, métricas, intended use, out-of-scope use, análise de fairness, vieses conhecidos e limitações técnicas.
- docs/system-card.md com escopo, fluxo de decisão, dependências, guardrails, cenários de risco (reward hacking, manipulação do contexto, abuso do assistente, violação de suitability) e plano de monitoramento.
- docs/lgpd-plan.md com base legal, finalidade, minimização, ciclo de retenção, mapeamento de identificadores e atributos protegidos, política de logs/telemetria e plano de resposta a incidentes.
- Relatório técnico de até 10 páginas cobrindo problema, base escolhida, enriquecimento sintético, modelagem como multi-armed bandit, comparação quantitativa, arquitetura-alvo Azure, ciclo MLOps, limitações, riscos, hipóteses, trabalhos futuros e referências.
- Pitch de até 10 minutos seguido por 5 minutos de perguntas, com slides versionados em PDF ou formato aberto e roteiro cobrindo problema/abordagem/demonstração/evidências/riscos/governança/impacto

- Demonstração ao vivo ou gravada da plataforma é desejável e soma pontos extras; o grupo deve indicar o cenário, registrar plano de contingência e versionar a gravação ou dataset de demonstração.
- Cobertura no pitch dos critérios de apresentação: FinOps (ROI, custo por serviço Azure, TCO); justificativa de arquitetura técnica com diagrama, fronteiras e alternativas descartadas; cenários de escala e redução por volume de requisições.
- Plano de revisão periódica do model card e do system card com responsáveis e cadência definidos.

Evidência de aceite: a banca encontra narrativa coerente de problema, solução, evidências, riscos, governança e valor de negócio, sem alegar prontidão para produção real regulada.

Critérios de avaliação


A avaliação segue o contrato da Fase 05:

Dimensão	Peso	O que a banca procura
Críticos de negócio	30%	Aderência ao problema escolhido, clareza de impacto, viabilidade, comunicação executiva
Validação técnica global	70%	Pipeline, MLOps, avaliação, observabilidade, segurança, governança, documentação e uso de PyTorch/MLflow quando aplicável

Os grupos devem definir métricas específicas para o desafio. Essas métricas precisam ser justificadas no relatório técnico e conectadas ao impacto de negócio, mas não substituem os critérios oficiais da fase.

Checklist antes do demo day

- README explica desafio, execução local e limitações; pipeline usa base Kaggle compatível com fonte, versão, licença e limitações.
- Base processada e enriquecimento sintético documentados e separados da base Kaggle original; experimentos rastreados em MLflow.
- Baseline e abordagem principal comparados com métricas justificadas; análise referencia Thompson Sampling e Nilos-UCB.
- Avaliação inclui golden set com pelo menos 20 exemplos; guardrails testados com cenários adversariais.
- Camada de retreino, teste, aprovação e promoção de novas políticas documentada.
- Serviço, API, notebook executável ou interface demonstrável funciona com instruções claras e log auditável de decisão.
- Arquitetura-alvo e plano de deploy usam exclusivamente serviços Azure, com plano de segredos via Key Vault e Managed Identity.
- Model Card, System Card e plano LGPD completos.
- Pitch separa problema, abordagem, demonstração, evidências, riscos e impacto.
- Pitch cobre FinOps (ROI, custo qualitativo por serviço Azure, TCO).
- Pitch justifica arquitetura técnica com diagrama, fronteiras e alternativas descartadas e apresenta cenários de escala e redução.
- Pitch inclui demonstração ao vivo ou gravada da plataforma em operação, com plano de contingência (desejável; soma pontos extras).

The background is a dark, abstract network visualization. It features a complex web of thin, glowing lines in shades of teal, blue, and orange, connecting numerous small, semi-transparent nodes. Some nodes are larger and more prominent, while others are tiny specks. The overall effect is a sense of dynamic connectivity and data flow, typical of a digital or biological network.

POSTECH